




RAG 2026：當向量搜尋遇上代理推理

企業級 99% 準確度 AI 架構的演進與實踐指南


「上下文盲視」揭示了 RAG 1.0 建立在脆弱的統計假象之上

企業痛點




企業餵入數萬份文件，系統卻頻繁引用 2023 年的舊合約來回答 2026 年的決策問題。

The Anatomy of Context Blindness



根本原因



語義相似性 $\neq$ 事實正確性。

向量空間的鄰近性僅代表詞彙分佈的接近，完全無視邏輯真實性與版本有效性。

單純的切片策略會導致準確度下降超過 60%。

向量資料庫依然是處理千萬級數據的極速堡壘

解決方案	核心優勢	最佳應用場景
 Pinecone	大規模 RAG（穩定性與擴展性）	企業級生產環境
 OpenSearch	混合搜尋精度（詞法+語義）	合規性嚴格環境
 PGVector	現有資料庫集成度	中小團隊與輕量開發
 Redis	極低延遲與內存運算（TTFT）	實時應用與語義緩存
 LanceDB	本地優先靈活性	邊緣運算與原型設計

結構性致命傷（The Fatal Flaw）

索引延遲與上下文混淆。尋找「增加預算」時，系統常因語義模糊撈出「削減開支」的片段。